

Predikcija broja osvojenih medalja i klasifikacija zemalja prema uspehu na letnjim olimpijskim igrama

Sara Crnomarković

oktobar 2025.

Sažetak

Cilj rada je predikcija rezultata zemalja na Letnjim olimpijskim igrama primenom javno dostupnih ekonomskih i demografskih indikatora (World Bank). Problem posmatramo u dve forme: (i) regresija ukupnog broja medalja i (ii) klasifikacija da li zemlja osvaja bar jednu medalju. Rad se sastoji od sledećih delova: priprema podataka (filtriranje na Letnje igre, deduplikacija timskih medalja, agregacija na nivou *zemlja-godina*, spajanje sa World Bank indikatorima), standardizacija obeležja i poređenje više modela. U regresiji testiramo Linear, Ridge, Random Forest i Puasonov model; u klasifikaciji Logističku regresiju, Random Forest, Naive Bayes i MLP. Najbolje rezultate u klasifikaciji daje MLP ($AUC = 0.861$), a u regresiji su razlike u RMSE umerene uz najniži MAE kod Random Foresta.

Uvod

Predviđanje broja medalja koje će neka zemlja osvojiti na Letnjim olimpijskim igrama predstavlja zanimljiv i izazovan zadatak u oblasti mašinskog učenja i statističkog modelovanja. Broj medalja zavisi od različitih faktora – od ekonomske razvijenosti (npr. bruto domaći proizvod), veličine populacije, pa do demografskih i društvenih pokazatelja kao što je očekivano trajanje života.

Cilj ovog rada je da se, korišćenjem javno dostupnih podataka o olimpijskim igrama i ekonomskim indikatorima iz baze Svetske banke, ispita da li se broj osvojenih medalja može uspešno modelovati i predvideti.

Naš pristup odvijao se u dva dela. U prvom delu posmatrali smo problem kao regresiju i pokušali da predvidimo tačan broj medalja po zemlji i po godini. Testirali smo više modela regresije: linearnu regresiju, Ridge regresiju, Random Forest i Puasonovu regresiju. Iako su modeli davali određene rezultate, primećeno je da problem postaje složen zbog činjenice da veliki broj zemalja na igrama ne osvoji nijednu medalju, kao i da je broj medalja dosta kompleksnija tema od predviđanja opšteg uspeha (tj osvajanja medalje ili ne).

Zbog toga smo u drugom delu rada problem posmatrali kao zadatak klasifikacije. Formulirali smo binarnu ciljnu promenljivu (`HasMedal`), koja označava da li je neka zemlja osvojila bar jednu medalju u datoj godini ili ne. Na ovom zadatku testirali smo više klasifikacionih algoritama: logističku regresiju, Random Forest, Naive Bayes i neuronske mreže.

Na ovaj način dobili smo i kvantitativne rezultate u vidu grešaka predikcije kod regresije, kao i tačnosti i AUC vrednosti kod klasifikacije. Upoređivanjem različitih modela u obe faze mogli smo da zaključimo koji modeli su bili najuspešniji i kakav je značaj pojedinih prediktora.

1 Priprema podataka


Koristimo tri tabele: `olympics.csv` (rezultati po sportisti i događaju), `noc_regions.csv` (mapiranje NOC → država) i `wb_development.csv` (World Bank indikatori po zemlji i godini).

Koraci obrade

- **Filtriranje:** zadržane su samo letnje igre; uklonjeni su redovi sa nedostajućim vrednostima u ključnim kolonama.
- **Mapiranje zemalja:** NOC kodovi su mapirani u naziv države (kolona `Nation`) preko `noc_regions.csv`.
- **Deduplikacija timskih medalja:** zadržan je po jedan zapis po (`Year`, `Event`, `Medal`, `Nation`) kako timske medalje ne bi bile brojane više puta.
- **Agregacija:** formiran je skup `Medals_number = count(Nation, Year)`.
- **Spajanje sa WB:** indikatori `population`, `GDP_current_US`, `life_expectancy_at_birth` pridruženi su po (`country`, `Year`).
- **Skaliranje:** numerička obeležja standardizovana su z -skorom.

Na ovaj način dobijene su dve radne baze:

1. **final_scaled** (za regresiju): (`Nation`, `Year`, `Medals`, $\tilde{X}$), gde je $\tilde{X}$ vektor standardizovanih WB obeležja. Sadrži samo parove sa `Medals` ≥ 1 .
2. **clf_scaled** (za klasifikaciju): puna mreža `Nation` $\times$ `Year` (sve zemlje iz WB i sve olimpijske godine); `Medals` postavljen na 0 gde nema zapisa; uvedena binarna meta `HasMedal`; obeležja standardizovana.



Slika 1: Korelaciona matrica ključnih obeležja i cilja

2 Regresioni modeli

U prvoj fazi istraživanja posmatrali smo problem kao zadatak regresije: cilj je bio da se za svaku zemlju i godinu predvidi tačan broj osvojenih medalja. Ispitani su sledeći modeli:

- **Linearni model** – osnovna linearna regresija bez regularizacije, koja predstavlja baznu liniju za poređenje sa složenijim pristupima. Model:

$$\hat{y} = \beta_0 + \sum_{j=1}^p \beta_j x_j.$$

- **Ridge regresija** – linearni model sa L_2 regularizacijom. Funkcija cilja glasi:

$$\min_{\beta} \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p \beta_j^2,$$

gde λ kontroliše jačinu regularizacije. Ridge ublažava problem multikolinearnosti i smanjuje mogućnost prenaučivosti.

- **Puasonova regresija** – model prilagođen broju pojava (count data). Pretpostavlja se da $y_i \sim P(\lambda_i)$, sa log-linearnom vezom:

$$\log(\lambda_i) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip},$$

pa je očekivani broj medalja $\hat{y}_i = e^{\beta_0 + \sum_j \beta_j x_{ij}}$.

- **Random Forest regressor** – ansambl metoda koja gradi veliki broj stabala odlučivanja i kombinuje njihove prognoze. Za T stabala $h_1(x), h_2(x), \dots, h_T(x)$, predikcija se računa kao

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x).$$

Random Forest omogućava da se uhvate složeniji i nelinearni odnosi između prediktora i broja medalja.

Svi modeli su trenirani na podacima o zemljama koje su osvajale medalje, a procenjeni pomoću metrika RMSE (korena srednje kvadratne greške) i MAE (srednje apsolutne greške). RMSE naglašava veća odstupanja, dok MAE daje prosečno odstupanje bez kvadriranja grešaka.

Tabela 1 prikazuje dobijene rezultate, dok su na slikama ??, ??, ?? i ?? predstavljeni scatter dijagrami predikcija u odnosu na stvarne vrednosti.

Model	RMSE	MAE
Linear	9.03	6.72
Ridge	9.14	6.89
Random Forest	9.62	5.90
Poisson	9.91	7.38

Tabela 1: Rezultati regresionih modela (RMSE i MAE)

2.1 Linearni model

Ovaj model predstavlja polaznu osnovu – pretpostavlja da svaki prediktor linearno i nezavisno doprinosi krajnjem ishodu. Izabran je jer je jednostavan za interpretaciju i često pruža jaku baznu liniju performansi kada su odnosi približno linearni (što smo pretpostavili iz preliminarne analize podataka). Međutim, linearni model ne može dobro da uhvati autlajere, odnosno ekstremne vrednosti koje značajno odstupaju od proseka.

Rezultati: Linearna regresija je na našem problemu dala solidne rezultate. Na test skupu ostvareni su $RMSE \approx 9.03$ i $MAE \approx 6.72$. To znači da se prosečna greška predviđanja kreće oko 6–7 medalja, dok su kvadratna odstupanja u proseku oko 9 medalja. Linearni model je imao najmanji RMSE među svim ispitivanim modelima, što ukazuje da daje najbolje ukupno uklapanje u smislu kvadratne greške.

Slika 2. prikazuje dijagram stvarnih u odnosu na predviđene vrednosti. Idealan slučaj bi bio da sve tačke leže na dijagonali (savršeno predviđanje). Vidimo da model generalno prati trend – zemlje sa više medalja dobijaju veće predikcije – ali sistematski potcenjuje najuspešnije zemlje (npr. SAD, Kinu, Rusiju). To je očekivano, jer ekstremno veliki brojevi medalja teško mogu biti tačno opisani linearnim pristupom bez dodavanja složenijih nelinearnih efekata. Ipak, za većinu zemalja linearni model daje razumne prognoze, što opravdava njegovu ulogu baznog modela.


2.2 Ridge regresija

Ridge regresija je proširenje linearne regresije koje uvodi L2 regularizaciju radi smanjenja prenaučivosti i stabilizacije parametara u prisustvu koreliranih obeležja.

Ridge je izabran jer smo očekivali korelacije među prediktorima (što je potvrđeno analizom), pa regularizacija može da poboljša stabilnost.

Rezultati: Ridge regresija je postigla vrlo slične performanse kao i obična linearna regresija. Na optimalno podešenoj regularizaciji dobijeni su $RMSE \approx 9.14$ i $MAE \approx 6.89$, što je tek neznatno lošije od linearnog modela (razlike manje od 2%). To pokazuje da linearni model nije bio značajno prenaučiv i da dodatna regularizacija nije donela vidljivo poboljšanje.

Na scatter dijagramu (Slika 2.) predviđene vrednosti su gotovo identične onima iz linearnog modela. Najveća odstupanja ponovo se javljaju kod zemalja sa vrlo velikim brojem medalja (30+), gde i Ridge sistematski potcenjuje vrednosti. Prednost Ridge modela je u stabilnijim koeficijentima – ako postoje dva snažno korelisana indikatora, on raspodeljuje težinu između njih, dok bi obična regresija mogla jednom dodeliti ekstremno veliku a drugom ekstremno malu vrednost. U našem slučaju, to nije značajno promenilo interpretaciju: ključni indikatori (populacija, BDP, očekivano trajanje života) i dalje ostaju najvažniji.



Slika 2: Stvarne vs. predikcije (levo Linearni, desno Ridge)

2.3 Puasonova regresija


Puasonova regresija je specifičan oblik generalizovanog linearnog modela za predviđanje celobrojnih vrednosti koje predstavljaju broj pojavljivanja događaja. U našem slučaju, broj osvojenih medalja tretira se kao takav događaj. Model pretpostavlja da $y_i \sim P(\lambda_i)$. Ovim oblikom svi prediktori imaju multiplikativan efekat, a predikcija je uvek nenegativna, što je u skladu sa prirodom podataka.

Rezultati: U našem slučaju Puasonova regresija dala je najslabije performanse. Postignuti su $RMSE \approx 9.91$ i $MAE \approx 7.38$, što su najveće greške među svim modelima. Model je često predviđao vrednosti u užem opsegu nego što su stvarni ishodi i davao pozitivnu prognozu i za zemlje bez medalja. To ukazuje da pretpostavka Pusonove raspodele nije idealna za naše podatke. Na slici 3. vidi se da model potcenjuje ekstremno uspešne zemlje i previše “vuče” predikcije ka sredini.

2.4 Random Forest regresija

Random Forest je nelinearni ansambl metod koji kombinuje veliki broj stabala odluke treniranih na različitim podskupovima podataka i obeležja. Svako stablo $h_t(x)$ daje sopstvenu prognozu, a konačni ishod je njihov prosek. Ovaj pristup omogućava hvatanje složenih nelinearnih odnosa i smanjuje prenaočenost u poređenju sa pojedinačnim stablom.

Rezultati: Random Forest je dao $RMSE \approx 9.62$ i $MAE \approx 5.90$. Iako je RMSE nešto veći nego kod linearnih modela, MAE je najmanji od svih razmatranih metoda, što znači da je tipične vrednosti pogodio preciznije. Najveće greške pojavljuju se kod zemalja sa ekstremno velikim brojem medalja (npr. SAD, Kina), koje su modelu teške za učenje. Scatter dijagram (Slika 3.) pokazuje da su predviđanja većine zemalja vrlo blizu dijagonale, ali postoje pojedini outlajeri kod veoma uspešnih država.




Slika 3: Stvarne vs. predikcije (levo Random Forest reg., desno Puasonova)

2.5 Poređenje regresionih modela

Linearni i Ridge modeli pokazali su vrlo slične rezultate, dok je Poisson regresija bila najslabija. Kao najbolji kompromis izabrali smo Random Forest, jer postiže najmanji MAE i pruža dodatne uvide kroz analizu važnosti obeležja, iako mu je RMSE nešto veći.

Takođe, Random Forest se pokazao kao daleko najbolji ukoliko bi regresija bila sprovedena na bazi koja ne sadrži samo zemlje koje su ostvarile uspeh na letnjim olimpijskim igrama (pa

takvima samo predviđamo broj medalja), već i one koje uopšte nisu osvojile medalju. U tom slučaju, ostali regresioni modeli su previše često imali predviđene vrednosti u okolini nule (jer je mnogo takvih država generalno, pa tako i u trening skupu), dok je Random Forest jedini uspeo da ipak uhvati strukturu podataka.



Slika 4: Važnost obeležja u Random Forest regresoru

3 Klasifikacioni modeli

Druga faza našeg rada bila je binarna klasifikacija: predvideti da li će zemlja osvojiti bar jednu medalju ($Y = 1$) ili ne ($Y = 0$). Isprobali smo više modela: logističku regresiju, Naivni Bayes, Random Forest i višeslojni perceptron (MLP). Svi modeli su ocenjivani prema tačnosti i AUC metrici.

3.1 Logistička regresija

Logistička regresija modeluje verovatnocu da zemlja osvoji medalju pomoću logističke funkcije:

$$P(Y = 1|x) = \frac{1}{1 + \exp(-(\beta_0 + \beta^T x))}.$$

Ovaj model smo odabrali jer je jednostavan za interpretaciju i služi kao bazna linija za poredjenje sa složenijim metodama. **Rezultat:** Logistička regresija kao bazni model dala je solidan rezultat (Accuracy ≈ 0.79 , AUC ≈ 0.76). Potvrđuje da ekonomski i demografski indikatori značajno utiču na šansu za medalju, ali jednostavna linearna granica nije dovoljno fleksibilna da uhvati sve obrasce.

3.2 Naivni Bayes

Naivni Bajes klasifikator primenjuje Bajesovo pravilo uz pretpostavku uslovne nezavisnosti obeležja:

$$P(Y = c|X) \propto P(Y = c) \prod_{j=1}^p P(X_j|Y = c).$$

Izabrali smo ga jer je veoma brz i može otkriti jasne razlike u distribucijama između klasa. **Rezultat:** Naivni Bayes je pokazao vrlo nisku tačnost (Accuracy ≈ 0.49), ali iznenađujuće

dobar AUC (≈ 0.74). To znači da razlikuje klase bolje nego što izgleda na osnovu tačnosti, ali previsoko procenjuje verovatnoću osvajanja medalje i generiše mnogo lažnih pozitivnih.

3.3 Random Forest

Random Forest gradi ansambl stabala odluke i odluku donosi većinskim glasanjem. Formalno, finalna prognoza je:

$$\hat{y} = \text{majority}\{h_1(x), h_2(x), \dots, h_T(x)\}.$$

Ovaj model smo koristili jer može da uhvati nelinearne odnose i interakcije između prediktora, te često daje najbolji balans preciznosti i robustnosti. **Rezultat:** Random Forest je bio jedan od najboljih modela. Ostvario je Accuracy ≈ 0.85 i AUC ≈ 0.85 . Pokazao se robusnim i dobro balansira preciznost i osetljivost. Pored toga omogućava analizu važnosti obeležja, pri čemu su broj sportista, BDP i populacija najvažniji faktori.

3.4 MLP


MLP je neuronska mreža koja primenjuje slojeve linearnih transformacija i nelinearnih aktivacija. Za binarnu klasifikaciju:

$$P(Y = 1|x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

gde je σ sigmoidna aktivacija. Odabrali smo ga jer može uhvatiti kompleksne obrasce u podacima i potencijalno postići najbolje rezultate. **Rezultat:** MLP je postigao Accuracy ≈ 0.84 i najveći AUC (≈ 0.86). To pokazuje da uspešno hvata kompleksnije obrasce u podacima i rangira primere nešto bolje od Random Forest-a. Međutim, zbog manje interpretabilnosti i većeg rizika od prenaučenosti, MLP nismo izabrali za finalni model.

3.5 Poređenje klasifikacionih modela

Logistička regresija dala je solidan rezultat (Accuracy ≈ 0.79 , AUC ≈ 0.76), što je bolje od naivne baze, ali slabije od naprednijih modela. Naivni Bayes je imaoisku tačnost (≈ 0.49), ali relativno dobar AUC (≈ 0.74), što pokazuje da često precenjuje pozitivnu klasu. Random Forest i MLP bili su najbolji: RF je postigao Accuracy ≈ 0.85 i AUC ≈ 0.85 , dok je MLP imao nešto manji Accuracy (≈ 0.84), ali najveći AUC (≈ 0.86).



Model	Accuracy	AUC
Logistic	0.785	0.760
Random Forest	0.852	0.848
Naive Bayes	0.487	0.735
MLP	0.843	0.861

Tabela 2: Rezultati klasifikacionih modela.

Slika 5: ROC krive za klasifikacione modele.

Zaključak

Na osnovu sprovedene analize, u radu smo primenili dva odvojena pristupa: regresione modele za predviđanje broja medalja kod zemalja koje su osvojile bar jednu medalju, i klasifikacione modele za detekciju da li će neka zemlja osvojiti medalju ili ne. Na ovaj način izdvojili smo dve komplementarne dimenzije problema: *koliko medalja* osvajaju zemlje koje jesu uspešne i *ko uopšte ulazi u grupu osvajača*.

Rezultati su pokazali da su linearni modeli (linearni i Ridge) dali dobre performanse i potvrdili da su glavni odnosi u podacima pretežno linearni, iako su imali sistematske greške kod ekstremnih vrednosti (najuspešnije zemlje). Puasonova regresija, iako teorijski prirodan izbor za brojeve događaja, imala je najslabiji učinak. Najbolji rezultati u regresiji postignuti su Random Forest modelom, koji je imao najmanju prosečnu apsolutnu grešku i pokazao robusnost u predviđanju za većinu zemalja.

Kod klasifikacije, logistička regresija i Naive Bayes poslužili su kao osnovni modeli, dok su Random Forest i MLP postigli najbolje performanse. Random Forest je imao najvišu tačnost, dok je MLP postigao nešto viši AUC; oba su značajno nadmašila linearne klasifikatore. Na kraju smo za praktičnu primenu izdvojili Random Forest, jer pruža i visoku tačnost i dodatnu interpretabilnost kroz važnost obeležja.

Kao što smo mogli i da očekujemo, klasifikacija je bila uspešnija od regresije jer je lakše predvideti opštu uspešnost od tačnog broja medalja. Možemo zaključiti da ekonomski i društveni faktori u velikoj meri utiču na uspešnost na olimpijskim igrama (veoma uspešne klasifikacije), a da na tačan nivo uspešnosti utiču nešto manje, mada je njihov uticaj i tu izražen (linearni modeli jesu bili uspešni, ali ne u toj meri).

Naši modeli su pokazali da i klasične metode i napredni algoritmi mogu dati pouzdane prognoze, a posebno da Random Forest nudi najbolji balans tačnosti i robusnosti. Ovaj rad time daje okvir za razumevanje i predviđanje olimpijskog uspeha na nivou zemalja.

Literatura

- [1] Olympic medals prediction project. *GitHub repository*. Dostupno na: <https://github.com/bdobkowski/Olympic-Medals-Prediction>
- [2] Lohmann, G., & Follert, F. (2018). Predicting Olympic medal wins with publicly available data: a machine learning approach. *Journal of Sports Analytics*, 4(4), 253–263.
- [3] Johnson, D. K. N., & Ali, A. (2016). A Tale of Two Seasons: Participation and Medal Counts at the Summer and Winter Olympic Games. *Social Science Quarterly*, 97(1), 38–54.

Dataset

Svi korišćeni podaci i baze preuzeti su iz GitHub repozitorijuma [1].